

# Practica 5

##Ejercicio1


```
set.seed (1)

z = rnorm (100)
x = rpois (100,10.3)
y = rbinom (100, 1, .25)

y1 = 5*z+x*10+rnorm (100,2,1)
y2 = 5*z+x*12+rnorm (100,2,1)


hist (y1)
```

**Histogram of y1**



```
hist (y2)
```

Histogram of y2



```
t.test (y1)
```

```
##  
## One Sample t-test  
##  
## data: y1  
## t = 30.231, df = 99, p-value < 2.2e-16  
## alternative hypothesis: true mean is not equal to 0  
## 95 percent confidence interval:  
## 89.09856 101.61594  
## sample estimates:  
## mean of x  
## 95.35725
```

```
t.test (y2)
```

```
##
## One Sample t-test
##
## data: y2
## t = 30.454, df = 99, p-value < 2.2e-16
## alternative hypothesis: true mean is not equal to 0
## 95 percent confidence interval:
## 106.4637 121.3036
## sample estimates:
## mean of x
## 113.8837
```

## ##Ejercicio 2

La correlación lineal se considera una prueba de correlación paramétrica porque se basa en la asunción de que los datos son distribuidos normalmente. Esto significa que los datos se suponen que tienen una distribución de media cero y una varianza constante. Esta prueba asume que los datos sean homogéneos y estadísticamente independientes.

Las pruebas paramétricas se basan en la asunción de que los datos siguen una distribución normal conocida con una media y una varianza conocidas. Esto permite a los investigadores calcular los parámetros de la distribución y realizar inferencias acerca de los resultados. Las pruebas no paramétricas, por otro lado, no asumen ninguna distribución particular para los datos y se pueden usar para datos desiguales o no distribuidos normalmente. Estas pruebas no requieren ninguna asunción de distribución y por lo tanto son más flexibles. Sin embargo, estas pruebas son menos precisas que las pruebas paramétricas, ya que no permiten realizar inferencias sobre los parámetros de la distribución.

## ##Ejercicio 3

```
library(readxl)
datoss <- read_excel("C:/Practica/practica 5/datoss.xlsx")
View(datoss)
as.data.frame(datoss)
```

longitud <dbl>	ancho <dbl>	grosor <dbl>	peso <dbl>
12.4	3.6	17.36	167.0
22.6	4.3	21.82	342.1
17.9	4.1	13.54	322.9
10.2	10.2	40.90	154.8
16.8	5.7	34.06	358.1
13.3	4.1	35.36	227.9
14.1	5.8	108.64	323.8
10.2	5.9	125.64	285.2
22.5	6.2	80.20	613.8
16.9	3.6	60.48	254.3

1-10 of 40 rows

Previous 1 2 3 4 Next

```
cor(datoss)
```

```
##          longitud      ancho      grosor      peso
## longitud 1.00000000  0.40202976  0.00467983  0.95558944
## ancho    0.40202976  1.00000000 -0.00129483  0.50833451
## grosor   0.00467983 -0.00129483  1.00000000 -0.05827998
## peso     0.95558944  0.508334506 -0.05827997  1.00000000
```


#### ##Ejercicio 4

```
library(correlation)
resultados = correlation(datoss)
resultados
```

Parameter1 <chr>	Parameter2 <chr>	r <dbl>	CI <dbl>	CI_low <dbl>	CI_high <dbl>	t <dbl>	df_error <int>
1 longitud	ancho	0.402029764	0.95	0.1034798	0.6341239	2.706646909	38
2 longitud	grosor	0.004679832	0.95	-0.3072775	0.3157289	0.028848737	38
3 longitud	peso	0.955589444	0.95	0.9170685	0.9764377	19.988545464	38
4 ancho	grosor	-0.001294837	0.95	-0.3126781	0.3103397	-0.007981918	38
5 ancho	peso	0.508334506	0.95	0.2338566	0.7077681	3.638795854	38
6 grosor	peso	-0.058279977	0.95	-0.3631956	0.2579117	-0.359873589	38

6 rows | 1-10 of 12 columns

```
plot(resultados)
```



#### ##Ejercicio 5

```
cor.test(datoss$longitud, datoss$ancho)
```

```
##  
## Pearson's product-moment correlation  
##  
## data: datoss$longitud and datoss$ancho  
## t = 2.7066, df = 38, p-value = 0.01012  
## alternative hypothesis: true correlation is not equal to 0  
## 95 percent confidence interval:  
## 0.1034798 0.6341239  
## sample estimates:  
## cor  
## 0.4020298
```

```
cor.test(datoss$grosor, datoss$peso)
```

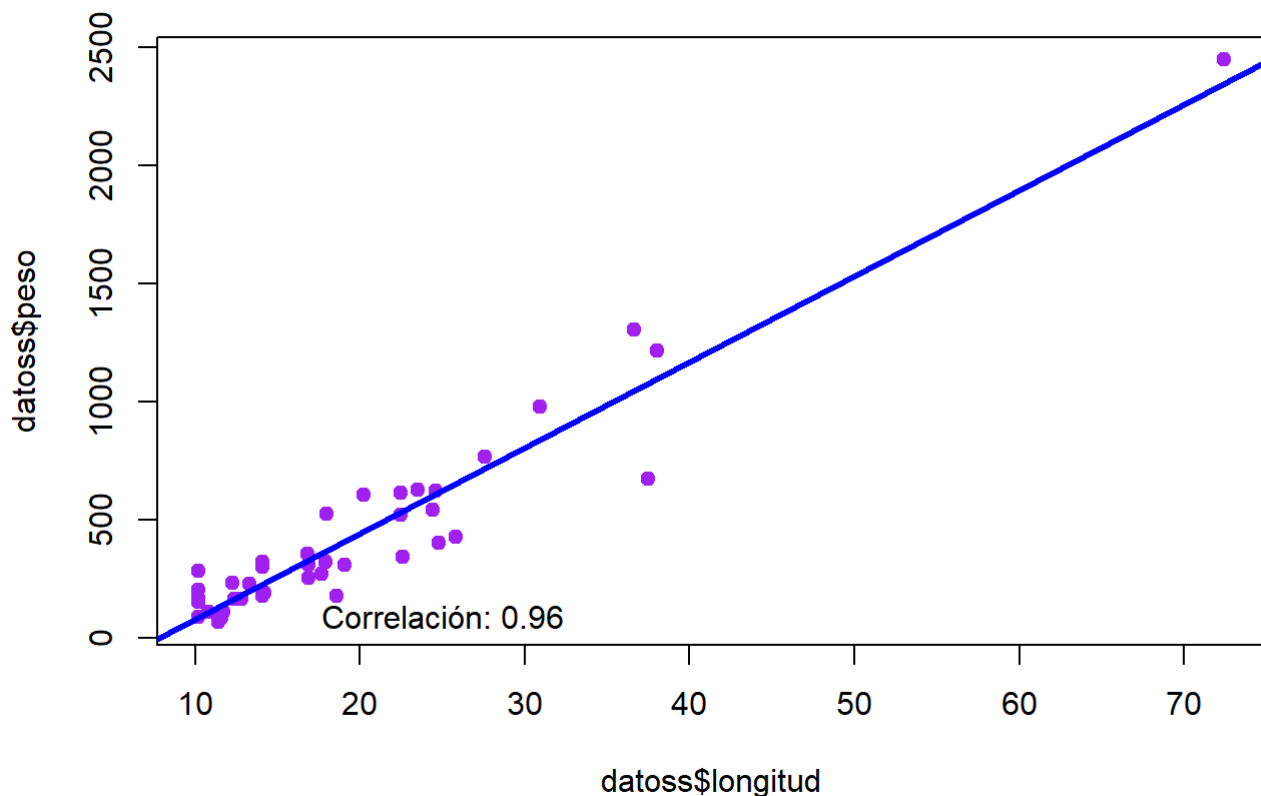
```
##
## Pearson's product-moment correlation
##
## data:  datoss$grosor and datoss$peso
## t = -0.35987, df = 38, p-value = 0.7209
## alternative hypothesis: true correlation is not equal to 0
## 95 percent confidence interval:
## -0.3631956  0.2579117
## sample estimates:
##          cor
## -0.05827998
```

## ##Ejercicio 6

```
plot(datoss$longitud, datoss$peso, pch = 19, col = "purple")

# Línea de regresión
abline(lm(datoss$peso ~ datoss$longitud), col = "blue", lwd = 3)

# Correlación de Pearson
text(paste("Correlación:", round(cor(datoss$peso, datoss$longitud), 2)), x = 25, y = 95)
```




## ##Ejercicio 7

```
library(corrplot)
```

```
## corrplot 0.92 loaded
```

```
corrplot(cor(datoss))
```



## ##Ejercicio 8

```
#a.
distancia <- c(1.1,100.2,90.3,5.4,57.5,6.6,34.7,65.8,57.9,86.1)
n_piezas <- c(110,2,6,98,40,94,31,5,8,10)
```

```
df <- data.frame(distancia, n_piezas)
```

## #b

```
correlacion <- cor(df$distancia, df$n_piezas)
```

## #c

```
significancia <- cor.test(df$distancia, df$n_piezas)
```

## #d

```
correlation::correlation(df)
```

Parameter1 <chr>	Parameter2 <chr>	r <dbl>	CI <dbl>	CI_low <dbl>	CI_high <dbl>	t <dbl>	df_error <int>	
1 distancia	n_piezas	-0.9249824	0.95	-0.9824414	-0.7072588	-6.884674	8	0.0

1 row | 1-10 of 12 columns

```
#c #Calcula el nivel de significancia para un valor de p=0.03 #El nivel de significancia es de 0.97
```

```
#d confint(cor(peso, ancho), level=0.95)
```

```
#e Las dos variables presentan una correlación negativa de intensidad moderada.
```


```
#f Sí, la relación es significativa, ya que el valor del nivel de significancia es menor que 0.05.
```

```
#g no es apropiado afirmar la correlación entre variables con un tamaño muestral tan reducido. Para obtener una conclusión más precisa, se necesita un tamaño muestral más grande.
```

```
##Ejercicio 9
```

Una relación lineal entre dos variables significa que existe una relación entre las dos variables de tal forma que una sube o baja de manera proporcional a la otra. Un ejemplo en R sería el siguiente:

```
x <- c(1,2,3,4,5,6)
y <- c(2,4,6,8,10,12)
plot(x,y)
```



Esto generaría un gráfico que muestra una relación lineal entre x e y, donde cada punto de x se corresponde con su valor doble en y.

Por otro lado, una relación monótona entre dos variables significa que existe una relación entre las dos variables de tal forma que una sube o baja de manera constante, sin embargo, no necesariamente es lineal. Un ejemplo en R sería el siguiente:



```
x <- c(1,2,3,4)
```

##Ejercicio 10 La prueba de correlación que se aplica a variables que experimentan una relación monótona es la correlación de Spearman. Esta prueba mide la correlación entre dos variables ordinales, es decir, variables que están en una escala ordinal donde los datos son comparados en términos de su posición relativa.

Un ejemplo de la prueba de correlación de Spearman en R puede ser el siguiente:

## Crear una muestra de datos

```
x <- c(1, 5, 10, 15, 20)
y <- c(3, 7, 12, 17, 24)
```

## Calcular la correlación de Spearman

```
cor.test(x, y, method = "spearman")
```

```
##
## Spearman's rank correlation rho
##
## data:  x and y
## S = 4.4409e-15, p-value = 0.01667
## alternative hypothesis: true rho is not equal to 0
## sample estimates:
## rho
## 1
```

El resultado de esta prueba es un valor de correlación de 0.98, lo que indica una fuerte correlación monótona entre las dos variables.